

سوال 1:

بخش 1: ابتدا دیتاست را به کمک کتابخانه pandas ورودی گرفتم و در متغیر df که همان Dataframe هست ذخیره کردم. سپس ستونهای مربوط به مترو و بی آر تی را به کمک کتابخانه matplotlib و دستور hist() رسم کردم.

بخش دوم: هر کدام از متغیرهای تصادفی X و Y که تعداد اتفاقات یک پیشامد (تعداد گذر مترو و اتوبوس) در یک بازه زمانی خاص یا را نشان می دهند که این همان توزیع پواسون است. از روی شکل نمودارهای آن ها هم می توان به این توزیع پی برد. برای محاسبه پارامترهای این دو توزیع پواسون هم از دستور mean() که برای کتابخانه pandas است استفاده میکنیم چون که پارامتر توزیع پواسون با میانگین آن برابر است و برای هم مترو و بی آر تی، آنها را محاسبه می کنیم که برای متغیر تصادفی X، پارامتر آن برابر 3.5316 و برای Y برابر 2.0636 می شود.

بخش سوم: در این قسمت از ما خواسته شده که density histogram را برای گذرهای مترو بکشیم.

برای این کار یکی از ورودی های تابع `hist()` که `density` هست را برابر با `True` قرار میدهیم.

بخش چهارم: در این قسمت باید نمودار توزیع برای گذر های مترو را بکشیم توسط پارامتری که در بخش دو بدست آوردیم و با بخش سوم نمودارها را مقایسه کنیم. برای این کار توسط تابع `poisson.pmf()` که در `scipy.stats` است نمودار توزیع را میکشیم و مشاهده میشود که نمودارهای بخش سوم و چهارم با تقریب خوبی بر هم منطبق هستند.

بخش پنجم: دو متغیر تصادفی X & Y از هم مستقل هستند. بنابراین جمعشان یعنی متغیر تصادفی Z یک متغیر تصادفی جدید با پارامتر مجموع پارامترهای X , Y میشود. نمودار این متغیر به کمک `stats.poisson` میکشیم. همچنین یکبار هم گذرهای مترو و بی آر تی را نظیر به نظیر درایه ها با هم جمع میکنیم و در یک دیتافریم ذخیره میکنیم (`df['Z']`). هیستوگرام این را هم رسم میکنیم. مشاهده میشود که دو نمودار رسم شده با تقریب خوبی بر هم منطبق هستند.

قسمت شش: توزیع W و پارامترهای آن را اینگونه بدست می آوریم:


مجموع دو متغیر تصادفی پواسون

○ فرض کنید X و Y دو متغیر تصادفی مستقل با توزیع پواسون باشند:
 $X \sim \text{Poi}(\lambda_1), Y \sim \text{Poi}(\lambda_2)$

○ حاصل جمع X و Y نیز دارای توزیع پواسون خواهد بود:
 $X + Y \sim \text{Poi}(\lambda_1 + \lambda_2)$

اثبات:

$$\begin{aligned}
 P(X + Y = n) &= \sum_{k=0}^n P(X = k, Y = n - k) \\
 &= \sum_{k=0}^n P(X = k)P(Y = n - k) \quad \leftarrow \text{استقلال } X \text{ و } Y \\
 &= \sum_{k=0}^n e^{-\lambda_1} \frac{\lambda_1^k}{k!} e^{-\lambda_2} \frac{\lambda_2^{n-k}}{(n-k)!}
 \end{aligned}$$



آمار و احتمال مهندسی
بهنام بهرک

4 of 31

مجموع دو متغیر تصادفی پواسون

$$\begin{aligned}
 P(X + Y = n) &= \sum_{k=0}^n e^{-\lambda_1} \frac{\lambda_1^k}{k!} e^{-\lambda_2} \frac{\lambda_2^{n-k}}{(n-k)!} \\
 &= e^{-(\lambda_1 + \lambda_2)} \sum_{k=0}^n \frac{\lambda_1^k}{k!} \frac{\lambda_2^{n-k}}{(n-k)!} \\
 &= \frac{e^{-(\lambda_1 + \lambda_2)}}{n!} \sum_{k=0}^n \frac{n!}{k! (n-k)!} \lambda_1^k \lambda_2^{n-k} \quad \leftarrow \text{بسط دو جمله‌ای} \\
 &= e^{-(\lambda_1 + \lambda_2)} \frac{(\lambda_1 + \lambda_2)^n}{n!} \sim \text{Poi}(\lambda_1 + \lambda_2)
 \end{aligned}$$

بخش 7 و 8: یک بار نمودار را با استفاده از توزیع و پارامتری که در قسمت قبل بدست آمده رسم کرده که از توزیع دو جمله

ای پیروی میکند و یک بار هم به صورت عملی احتمال X به شرط اینکه $X + Y$ برابر 8 شود را حساب کرده و نمودار این دو را رسم میکنیم. این دو نمودار هم بر هم با تقریب خوبی منطبق اند.

سوال 2:

بخش اول و دوم: در این قسمت باید تابعی بنویسیم که مقادیر k و n را دریافت می کند و هر دفعه یک عدد تصادفی به عنوان کوپن با استفاده از `numpy.randint()` بسازد و تعداد دفعات لازم برای دیدن تمام n کوپن را حساب کند و k دفعه این را تکرار و انجام دهد و سپس میانگین جواب آزمایش ها را برگرداند.

اگر این آزمایش ها را به تعداد زیاد تکرار کنیم ($k \rightarrow \infty$)

مشاهده میشود که این مقدار به $n \lg n$ میل میکند.

(29.316)

to collect all n coupons, we need

$$T = T_1 + T_2 + \dots + T_n.$$

So

$$E[T] = E[T_1] + E[T_2] + \dots + E[T_n].$$

After collecting $k - 1$ coupons, for next purchase:

- Failure = getting coupon you already have.
There are $k - 1$ choices.
- Success = getting a new coupon.
There are $n - k + 1$ choices.

Then T_k is **geometric** random variable with
success probability $p = \frac{n - k + 1}{n}$.

$$\text{So } E[T_k] = \frac{1}{p} = \frac{n}{n - k + 1}.$$

$$\begin{aligned} E[T] &= E[T_1] + E[T_2] + E[T_3] + \dots + E[T_n] \\ &= \frac{n}{n} + \frac{n}{n-1} + \frac{n}{n-2} + \dots + \frac{n}{1} \\ &= n \left(\frac{1}{n} + \frac{1}{n-1} + \frac{1}{n-2} + \dots + \frac{1}{1} \right) \\ &= n \left(1 + \frac{1}{2} + \frac{1}{3} + \dots + \frac{1}{n} \right). \end{aligned}$$

This is **harmonic series**, and

$$E[T] \text{ is approximately } n \int_1^n \frac{1}{x} dx = n \log n.$$

(این عکس ها از موضوع تمرین که در یک pdf بود
برداشتم 😊 البته این موضوع در کلاس هم اثبات شده)

بخش سوم و چهارم و پنجم:

$$T = X$$

هر کدام از T_i ها از توزیع هندسی پیروی میکنند اما P هر کدام متفاوت از دیگری است چون پس از مشاهده یک کوپن، احتمال مشاهده کوپن بعدی به دلیل دیده شدن یک سری کوپن از آنها تغییر می کند برای هر کدام از این T_i ها MGF را به صورت زیر محاسبه می کنیم:

$$\phi_X(s) = \sum_{k=1}^{\infty} (1-p)^{k-1} p e^{ks} = p e^s \sum_{m=0}^{\infty} ((1-p)e^s)^m = \frac{p e^s}{1 - (1-p)e^s}$$

الان هر کدام از این T_i ها را به صورتی تابعی از s و با استفاده از sympy و p که برای هر کدام بدست می آوریم، حساب میکنیم و در نهایت امید ریاضی T می شود مجموع امید ریاضی این T_i ها. MGF متغیر تصادفی T را حساب کردیم، با توجه به اینکه مشتق اول تابع MGF در نقطه $s=0$ برابر گشتاور مرتبه اول T یا همان همان امید ریاضی T است، امید ریاضی T را هم از این طریق بدست می آوریم.

که برابر 29.2896825396826 می شود و تقریباً برابر مقداری است که در قسمت قبل بدست آوردیم.

سوال 4:

قسمت اول و دوم و سوم:

ابتدا دیتاست را دریافت می کنیم و طبق گفته سوال اعداد 201 و 202 ام را از دیتافریم حذف می کنیم و با قراردادن threshold اعداد را باینری می کنیم. سپس در قسمت 3، یک سطر با label 8 و یا با label 9 را انتخاب کرده و آن را در جایی (آرایه) ذخیره می کنیم و به یک آرایه $28 * 28$ تبدیل می کنیم با استفاده از `numpy.reshape()` چون هر تصویر از 784 پیکسل تشکیل شده و یک تصویر $28 * 28$ تشکیل می شود. الان هم به کم `matplotlib.pyplot.imshow()` تصویر آن را میکشیم.

بخش چهار: بخش هایی که باید انجام بدهیم در صورت سوال آمده:

```
# calculate P(N = n | Y = p) which is a bernouli distribution
# calculate integral(0 -> 1) fy * pny
## pny =
## integral =
## post =
```


بعد از انجام این بخش، نمودار توزیع کشیده میشود و مد و میانگین به هم بسیار نزدیک هستند چون داده ها به تعداد خوبی هستند و p برابر با 0.67 میشود. که همان مد یا میانگین توزیع بتا پسین میشود.